

Elaborazione del Linguaggio Naturale a.a. 2026/2027

Esercitazione 01 del 01/10/2026 – 07/10/2026

Si consideri il data set del sub-task A della competizione HODI@EVALITA 2023 di classificazione binaria di tweet omotransfobici.

L'esercitazione richiede di:

- Caricare e analizzare il data set in Pandas
- Sostituire le emoji con testo standardizzato, per esempio tramite la libreria `emoji`, o con `TweetTokenizer`
- Procedere, utilizzando NLTK, a:
 - o Eliminare le stopwords
 - o Tokenizzare il testo in parole
 - o Lemmatizzare le parole
- Apprendere il modello a bigrammi e trigrammi
- Confrontare la Perplexity media dei due modelli sul test set
- Far generare ai due modelli 5 post di lunghezza 15 parole
- Costruire un embedding numerico dei post sulla base del modello a trigrammi e del modello a bigrammi
- Eseguire il task di classificazione binaria con un modello a scelta e ricerca degli iperparametri sia per i bigrammi sia per i trigrammi
- Confrontare le prestazioni in termini di F1 macro