Elaborazione del Linguaggio Naturale a.a. 2026/2027

Esercitazione 03 del 21/10/2026

Si consideri il data set WiC-ITA (https://wic-ita.github.io/) relativo alla competizione di Word Sense Disambiguation all'interno della conferenza EVALITA 2023, i cui set di train, validation e test sono all'interno della cartella di questa esercitazione. Il data set riporta, per ogni record, un lemma, una coppia di frasi, gli span del lemma all'interno di ciascuna frase ed una label binaria che indica se la parola ha lo stesso senso (label 1) o meno (label 0) in ognuna delle due frasi. Con riferimento al Subtask 1 (classificazione binaria in lingua italiana) si dovrà creare una baseline di etichettatura che utilizzi i synset di WordNet del lemma ed un classificatore binario che utilizzi gli embedding word2vec come feature di ingresso.

L'esercitazione richiede di:

- Creare la baseline:
  - Importare WordNet in Italiano usando il package `wn` da installare
  - Per ogni data set (train, validation, test) e per record estrarre tutti i synset del lemma e calcolare la sovrapposizione tra la definizione e gli esempi del synset e dei suoi cosiddetti "lemmi associati" con ogni singola frase della coppia utilizzando la similarità di Jaccard
  - Etichettare ogni frase della coppia con il synset che ha il valore massimo dello score di Jaccard
  - Generare la label 1 se le etichette di synset sono le stesse per entrambe le frasi della coppia e 0 in caso contrario
  - Calcolare l'F1-score per i tre data set
- Costruire il classificatore:
  - Installare e importare il package `gensim` tramite `pip` o `conda`
  - Calcolare gli embedding `word2vec` per il corpus costituito dalle "singole" sentence, dalle definizioni e dagli esempi di tutti i synset di ogni lemma insieme con quelli dei cosiddetti "lemmi associati" a ciascun synset.
  - Costruire un embedding, per ogni record del training set, ottenuto tramite concatenazione dell'embedding `word2vec` del lemma e degli embedding `word2vec` medi di tutte le parole delle due sentence da cui avremo rimosso preventivamente le stop-word.
  - Implementare un MLP con un certo numero di strati densi per eseguire la classificazione espungendo un validation set pari al 10% del training set e testando sul data set denominato `validation.jsonl` (o `validation.parquet`)
  - Calcolare l'F1-score per i tre data set

Il classificatore supera la baseline? Le performance migliorano se eseguiamo anche la lemmatizzazione delle parole nelle sentence? Le performance migliorano con altri embedding come fasttext o GloVe?

Proviamo a costruire la regola del parallelogramma dal modello `word2vec` che abbiamo addestrato per quattro termini a vostra scelta.