



**Università
degli Studi
di Palermo**



Processing del testo

CORSO DI ELABORAZIONE DEL LINGUAGGIO NATURALE

a.a. 2026/2027

Prof. Roberto Pirrone



Elaborare il
testo: le basi

Espressioni regolari



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Espressioni regolari

- Un linguaggio formale per descrivere stringhe di testo
- Come cercare una qualsiasi di queste forme?
 - woodchuck
 - woodchucks
 - Woodchuck
 - Woodchucks



Espressioni regolari: disgiunzioni

- Lettere tra parentesi quadre []

Pattern	Significato
<code>[wW]oodchuck</code>	Woodchuck, woodchuck
<code>[1234567890]</code>	Una cifra qualsiasi

- Intervalli `[A-Z]`

Pattern	Significato	
<code>[A-Z]</code>	Una maiuscola	<u>D</u> renched Blossoms
<code>[a-z]</code>	Una minuscola	<u>m</u> y beans were impatient
<code>[0-9]</code>	Una sola cifra	Chapter <u>1</u> : Down the Rabbit Hole

Espressioni regolari: disgiunzione negata

- Negazioni [^ S s]
 - ^ indica negazione solo se è il primo carattere in []

Pattern	Significato	
[^ A - Z]	Non una maiuscola	O <u>y</u> fn pripetchik
[^ S s]	Né 'S' né 's'	<u>I</u> have no exquisite reason"
[^ e ^]	Né e né ^	Look h <u>e</u> re
a ^ b	Lo schema a ^ b	Look up <u>a ^ b</u> now

Espressioni regolari: altre disgiunzioni


- Woodchuck è un altro nome per groundhog!
- La barra verticale | indica disgiunzione

Pattern	Significato
<code>groundhog woodchuck</code>	woodchuck
<code>yours mine</code>	yours
<code>a b c</code>	= <code>[abc]</code>
<code>[gG]roundhog [Ww]oodchuck</code>	Woodchuck



Espressioni regolari: ? * + .

Pattern	Significato	
colou?r	Carattere precedente opzionale	<u>color</u> <u>colour</u>
oo*h!	0 o più ripetizioni del carattere	<u>oh!</u> <u>ooh!</u> <u>oooh!</u> <u>ooooh!</u>
o+h!	1 o più ripetizioni del carattere	<u>oh!</u> <u>ooh!</u> <u>oooh!</u> <u>ooooh!</u>
baa+		<u>baa</u> <u>baaa</u> <u>baaaa</u> <u>baaaaa</u>
beg.n		<u>begin</u> <u>begun</u> <u>begun</u> <u>beg3n</u>



Stephen C Kleene

Kleene *, Kleene +

Espressioni regolari: ancore [^] ^{\$}

Pattern	Esempi
[^] [A-Z]	<u>P</u> alo Alto
[^] [^A-Za-z]	<u>1</u> <u>"</u> Hello <u>"</u>
\. ^{\$}	The end <u>.</u>
. ^{\$}	The end <u>? The end!</u>

Esempio

- Trova tutte le occorrenze della parola “the” in un testo.

the

Non trova le forme con iniziale maiuscola

[tT]he

Trova anche other o theology

[^a-zA-Z][tT]he[^a-zA-Z]

Riepilogo

- Le espressioni regolari hanno un ruolo molto ampio
 - Sequenze complesse di espressioni regolari sono spesso il primo modello di elaborazione del testo
- Per compiti complessi usiamo il Machine/Deep Learning
 - Le espressioni regolari servono nel pre-processing o come caratteristiche dei classificatori
 - Sono utili per cogliere generalizzazioni

Elaborare il
testo: le basi

Altre espressioni regolari:
sostituzioni ed ELIZA

Sostituzioni

- Sostituzione in Python e nei comandi UNIX:
- `s/regex1/pattern/`
- ad es.:
- `s/colour/color/`

Gruppi di cattura

- Vogliamo racchiudere tutti i numeri tra parentesi angolari:

the 35 boxes → *the <35> boxes*

- Usare parentesi () per “catturare” uno schema in un registro numerato (1, 2, 3...)

- Usare \1 per riferirsi al contenuto del gruppo di cattura

$s / ([0-9] +) / <\backslash 1> /$

Gruppi di cattura: più registri

- `/the (.*)er they (.*) , the \1er we \2/`
- Corrisponde a
 - *the faster they ran, the faster we ran*
- Ma non a
 - *the faster they ran, the faster we ate*

E se non volessimo catturare?

Le parentesi hanno due funzioni: raggruppare e catturare

Gruppi senza cattura: aggiungere ?: dopo la parentesi:

- `/ (? : some | a few) (people | cats) like some \1 /`
- **corrisponde a**
 - `some cats like some cats`
- **ma non a**
 - `some cats like some some`

Asserzioni di lookahead

- `(?= pattern)` è vera se lo schema corrisponde, ma ha **ampiezza nulla: non avanza il puntatore**
- `(?! pattern)` è vera se lo schema non corrisponde
- Come trovare, a inizio riga, una parola qualsiasi che non inizi con “Volcano”:
 - `/^(?!Volcano) [A-Za-z]+/`

Un'applicazione semplice: ELIZA

- Primo sistema NLP che imitava uno psicoterapeuta rogersiano
 - Joseph Weizenbaum, 1966.
 - Simulatore di ELIZA:
<https://psych.fullerton.edu/mbirnbaum/psych101/eliza.htm>
- Riconosce schemi di testo, ad esempio:
 - "I need X"e li trasforma, ad esempio, in
 - "What would it mean to you if you got X?"

Un'applicazione semplice: ELIZA

Men are all alike.

IN WHAT WAY

They're always bugging us about something or other.

CAN YOU THINK OF A SPECIFIC EXAMPLE

Well, my boyfriend made me come here.

YOUR BOYFRIEND MADE YOU COME HERE

He says I'm depressed much of the time.

I AM SORRY TO HEAR YOU ARE DEPRESSED

Come funziona ELIZA

- s/. * I'M (depressed|sad) . */I AM SORRY TO HEAR YOU ARE \1/
 - s/. * I AM (depressed|sad) . */WHY DO YOU THINK YOU ARE \1/
 - s/. * all . */IN WHAT WAY?/
 - s/. * always . */CAN YOU THINK OF A SPECIFIC EXAMPLE?/
-
- Esercizio: scrivere un'ELIZA italiana in Python

Elaborare il testo: le basi

Normalizzazione delle parole e altri aspetti



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Normalizzazione del testo

- Ogni compito NLP richiede di normalizzare il testo:
 1. Tokenizzare (segmentare) le parole
 2. Normalizzare le forme delle parole
 3. Segmentare le frasi

Lo vedremo dopo



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Normalizzazione delle parole

- Portare parole/token a una forma standard
 - U.S.A. o USA
 - uhhuh o uh-huh
 - Fed o fed
 - am, is, be, are

Conversione in minuscolo

- In applicazioni come IR: convertire in minuscolo
 - Gli utenti tendono infatti a usare le minuscole
 - Possibile eccezione: maiuscole a metà frase?
 - ad es., **General Motors**
 - **Fed** vs. **fed**
 - **SAIL** vs. **sail**
- Per sentiment, traduzione, estrazione di informazioni
 - Maiuscole utili (**US** rispetto a **us** è importante)

Lemmatizzazione

Rappresentare le parole con il lemma, la radice condivisa
= la forma del lemma nel dizionario:

- *am, are, is* → *be*
- *car, cars, car's, cars'* → *car*
- Italiano **amerò, amavi** → **amare**
- *He is reading detective stories*
→ *He be read detective story*

Lemmatizzazione tramite analisi morfologica

- **Morfemi:**

- Le piccole unità di significato che compongono le parole
- **Radici:** le unità centrali portatrici di significato
- **Affissi:** parti unite alle radici, spesso con funzione grammaticale

- **Analizzatori morfologici:**

- Scompongono *cats* nei due morfemi *cat* e *s*
- Analizziamo l'italiano *vorrei amarti mentre stai mangiando* con lo strumento [LinguA](#) dell'Istituto di Linguistica Computazionale del CNR

Stemming

- Ridurre alle radici tagliando gli affissi in modo grezzo

This was not the map we found in Billy Bones's chest, but an accurate copy, complete in all things-names and heights and soundings-with the single exception of the red crosses and the written notes.

Thi wa not the map we found in Billi Bone s chest but an accur copi complet in all thing name and height and sound with the singl except of the red cross and the written note

Stemmer di Porter

- Una sequenza di regole di riscrittura applicate in serie
 - Una cascata: l'uscita di ogni passo alimenta il successivo
- Alcune regole di esempio:

ATIONAL → ATE (e.g., relational → relate)

ING → ε if stem contains vowel (e.g., motoring → motor)

SSSES → SS (e.g., grasses → grass)

Segmentazione in frasi

! e ? sono poco ambigui, ma il **punto** “.” è molto ambiguo

- Confine di frase
- Abbreviazioni come Inc. o Dr.
- Numeri come .02% o 4.3

Algoritmo comune: prima tokenizzare. Regole o ML classificano il punto come (a) parte di una parola o (b) confine di frase.

- Può aiutare un dizionario di abbreviazioni

Poi si possono spesso segmentare le frasi con regole basate su questa tokenizzazione.

Rimozione delle stopwords

LINGUAGGIO / NLTK

Le stopwords nel testo

Stopword italiane • evidenziazione progressiva

00 / 46 occorrenze

Secondo un'antica tradizione pagana alpina la marmotta può indicare il tempo futuro tramite una sua insolita capacità meteorologica. Secondo alcune usanze statunitensi e canadesi, una marmotta che venga svegliata il 2 febbraio osserverebbe la propria ombra. Se non la vede, per la giornata nuvolosa, si ipotizza una primavera precoce, se invece vede la propria ombra si rifugia subito nella tana per tornare a dormire, dato che si attendono almeno altre sei settimane di freddo e gelo. Tale tradizione, che viene cristianizzata come giorno della Candelora e festeggiata ancora oggi in molte parti d'Italia, cade il 2 febbraio, giorno a metà strada tra solstizio d'inverno e equinozio di primavera.

La tradizione ha avuto una fortuna particolare negli Stati Uniti e nel Canada (Giorno della marmotta)

Fonte: NLTK • corpus stopwords / italian

Confronto in minuscolo; parole separate agli apostrofi; nessuna analisi del contesto.

- *Tutte queste parole veicolano davvero significato?*



Università
degli Studi
di Palermo



Rimozione delle stopwords

Stopword: parole molto frequenti nel corpus che non contribuiscono al significato centrale del testo.

Si eliminano dopo la tokenizzazione usando un dizionario.