



**Università
degli Studi
di Palermo**



POS Tagging e NER

CORSO DI NATURAL LANGUAGE PROCESSING (ELABORAZIONE DEL LINGUAGGIO NATURALE)

a.a. 2026/2027

Prof. Roberto Pirrone



Parti del discorso

- Dalle più antiche tradizioni linguistiche (Yaska e Panini V sec. a.C., Aristotele IV sec. a.C.), nasce l'idea che le parole possano essere classificate in categorie grammaticali.
 - Parti del discorso, classi di parole ovvero POS e POS tags
- 8 parti del discorso sono attribuite a Dionisio Trace di Alessandria (circa I sec. a.C.):
 - nome, verbo, pronome, preposizione, avverbio, congiunzione, participio, articolo
- Queste categorie sono rilevanti per l'NLP oggi.

Due classi di parole: Aperte vs. Chiuse

- Parole di classe chiusa

- Solitamente sono *function words*: parole brevi, frequenti e con funzione grammaticale

- articoli: **a, an, the**
- pronomi: **she, he, I**
- preposizioni: **on, under, over, near, by, ...**

- Parole di classe aperta

- Solitamente sono *content words*: Nomi, Verbi, Aggettivi, Avverbi
- Includono le interiezioni: **oh, ouch, uh-huh, yes, hello**
- Si possono aggiungere nuovi nomi e verbi come like *iPhone* or *to fax*

Parole di classe aperta("content")

Nomi

Propri

Janet
Italy

Comuni

cat, cats
mango

Verbi

Principali

eat
went

Aggettivi

old green tasty

Avverbi

slowly yesterday

Numeri

122,312
one

Interiezioni

Ow hello

... more

Parole di classe chiusa("function")

Articoli

the some

Congiunzioni

and or

Pronomi

they its

Ausiliari

can
had

Preposizioni

to with

Particelle

off up


... more

Part-of-Speech Tagging

- Il task consiste nell'assegnare una *part-of-speech* a ogni parola di un testo.
- Spesso le parole possono avere più di un POS.
- **book**:
 - VERB: (**Book** that flight)
 - NOUN: (Hand me that **book**).

Part-of-Speech Tagging

Si effettua una mappatura da una sequenza di parole $x_1, \dots, x_n$ a una sequenza di tag POS $y_1, \dots, y_n$.



"Universal Dependencies" Tagset

	Tag	Description	Example
Open Class	ADJ	Adjective: noun modifiers describing properties	<i>red, young, awesome</i>
	ADV	Adverb: verb modifiers of time, place, manner	<i>very, slowly, home, yesterday</i>
	NOUN	words for persons, places, things, etc.	<i>algorithm, cat, mango, beauty</i>
	VERB	words for actions and processes	<i>draw, provide, go</i>
	PROPN	Proper noun: name of a person, organization, place, etc..	<i>Regina, IBM, Colorado</i>
	INTJ	Interjection: exclamation, greeting, yes/no response, etc.	<i>oh, um, yes, hello</i>
Closed Class Words	ADP	Adposition (Preposition/Postposition): marks a noun's spacial, temporal, or other relation	<i>in, on, by under</i>
	AUX	Auxiliary: helping verb marking tense, aspect, mood, etc.,	<i>can, may, should, are</i>
	CCONJ	Coordinating Conjunction: joins two phrases/clauses	<i>and, or, but</i>
	DET	Determiner: marks noun phrase properties	<i>a, an, the, this</i>
	NUM	Numeral	<i>one, two, first, second</i>
	PART	Particle: a preposition-like form used together with a verb	<i>up, down, on, off, in, out, at, by</i>
	PRON	Pronoun: a shorthand for referring to an entity or event	<i>she, who, I, others</i>
Other	SCONJ	Subordinating Conjunction: joins a main clause with a subordinate clause such as a sentential complement	<i>that, which</i>
	PUNCT	Punctuation	<i>; , ()</i>
	SYM	Symbols like \$ or emoji	<i>\$, %</i>
	X	Other	<i>asdf, qwfg</i>

Esempi di frasi inglesi "Taggate"

- There/**PRO** were/**VERB** 70/**NUM** children/**NOUN** there/**ADV** ./**PUNC**
- Preliminary/**ADJ** findings/**NOUN** were/**AUX** reported/**VERB** in/**ADP** today/**NOUN** 's/**PART** New/**PROPN** England/**PROPN** Journal/**PROPN** of/**ADP** Medicine/**PROPN**

Proviamo on line su <https://lindat.mff.cuni.cz/services/udpipe/>

Sample "Tagged" Italian sentences

Esercizio:

Treebank: termine usato per indicare un corpus in cui la struttura sintattica/semantica delle frasi è annotata, permettendo di ottenere "alberi di parsing".

Eseguire il parsing **manuale** delle seguenti frasi italiane usando il tagset della UD Italian Stanford Dependency

Treebank e confrontare il risultato con il *POS tagger* online:

- Ieri l'altro ho visto Giovanni che prendeva un caffè
- M'illumino d'immenso

Perché il Part of Speech Tagging?

- Può essere utile per altri task di NLP:
 - **Parsing:** il *POS tagging* può migliorare il *parsing* sintattico.
 - **Machine Translation:** per il riordino di aggettivi e nomi (es. dallo spagnolo all'inglese).
 - **Sentiment Analysis:** per distinguere aggettivi o altri POS.
 - **Text-to-speech:** per decidere come pronunciare parole come "lead" o "object".

Perché il Part of Speech Tagging?

- Utile anche per task computazionali di analisi linguistica:
 - Per monitorare le parti del discorso nello studio di cambiamenti linguistici (es. neologismi, slittamenti di significato).
 - Per monitorare le parti del discorso nella misurazione della similarità di significato.

Quanto è difficile il POS tagging in inglese?

- Circa il 15% dei tipi di parole (*word types*) è ambiguo
 - Di conseguenza, l'85% non è ambiguo (es. *Janet* è sempre PROPN, *hesitantly* è sempre ADV).
- Tuttavia, quel 15% di parole ambigue tende a essere molto comune.

Quanto è difficile il POS tagging in inglese?

- Complessivamente, circa il 60% dei *token* in un testo è ambiguo.
- Ad esempio, *back*
earnings growth took a *back*/ADJ seat
a small building in the *back*/NOUN
a clear majority of senators *back*/VERB the bill
enable the country to buy *back*/PART debt
I was twenty-one *back*/ADV then

Performance del POS tagging in inglese

- L'accuratezza dei tag (*tag accuracy*) è di circa il 97% , un valore stabile da ben oltre 10 anni.
- Modelli come HMM, CRF e BERT hanno performance simili.
- L'accuratezza umana è più o meno la stessa.

Performance del POS tagging in inglese

- Tuttavia, la *baseline* è già del 92%!
 - La *baseline* è la performance del metodo più semplice possibile.
- Una *baseline* importante è la most frequent class baseline:
 - Taggare ogni parola con il suo tag più frequente.
 - Taggare le parole sconosciute come nomi.
- Il task è in parte facile perché molte parole non sono ambigue.

Fonti di informazione per il POS tagging

Janet will back the bill
AUX/NOUN/VERB? NOUN/VERB?

- Probabilità a priori della coppia parola/tag:
 - "will" è solitamente un AUX.
- Identità delle parole vicine:
 - "the" suggerisce che la parola successiva non sia un verbo.

Fonti di informazione per il POS tagging

Janet will back the bill
AUX/NOUN/VERB? NOUN/VERB?

- Morfologia e forma delle parole

- Prefissi **unable:** **un-** → ADJ
- Suffissi **importantly:** **-ly** → ADJ
- Maiuscole **Janet:** **CAP** → PROPN

Named Entity Recognition (NER)

- Una *Named Entity* è, nella sua accezione principale, qualsiasi cosa a cui ci si possa riferire con un nome proprio.
- I 4 tag più comuni sono:
 - **PER** (Persona): “Marie Curie”
 - **LOC** (Luogo): “New York City”
 - **ORG** (Organizzazione): “Stanford University”
 - **GPE** (Entità Geo-politica): “Boulder, Colorado”

Named Entity Recognition (NER)

- Una *Named Entity* è, nella sua accezione principale, qualsiasi cosa a cui ci si possa riferire con un nome proprio.
- Spesso si tratta di espressioni multi-parola.
- Il termine viene esteso anche a elementi che non sono entità, come date, orari e prezzi.

Named Entity tagging

- Il task del *Named Entity Recognition* (NER) consiste nel:
 1. Trovare le porzioni di testo (*span*) che costituiscono nomi propri.
 2. Taggare il tipo di entità.

NER output

Citing high fuel prices, [ORG United Airlines] said [TIME Friday] it has increased fares by [MONEY \$6] per round trip on flights to some cities also served by lower-cost carriers. [ORG American Airlines], a unit of [ORG AMR Corp.], immediately matched the move, spokesman [PER Tim Wagner] said. [ORG United], a unit of [ORG UAL Corp.], said the increase took effect [TIME Thursday] and applies to most routes where it competes against discount carriers, such as [LOC Chicago] to [LOC Dallas] and [LOC Denver] to [LOC San Francisco].

Perché il NER è utile?

- **Sentiment Analysis:** per analizzare il sentiment verso un'azienda o una persona.
- **Question Answering:** per rispondere a domande su una specifica entità.
- **Information Extraction:** per estrarre fatti su entità da un testo.

Perché il NER è difficile?

- **Segmentazione:** a differenza del POS tagging, nel NER bisogna prima identificare e segmentare le entità.
- **Ambiguità del tipo.**

[PER Washington] was born into slavery on the farm of James Burroughs.
[ORG Washington] went up 2 games to 1 in the four-game series.
Blair arrived in [LOC Washington] for what may well be his last state visit.
In June, [GPE Washington] passed a primary seatbelt law.

BIO Tagging

- Come trasformare questo problema in un task di *sequence labeling* (come il POS tagging), con un tag per ogni parola?
- [PER Jane Villanueva] of [ORG United] , a unit of [ORG United Airlines Holding] , said the fare applies to the [LOC Chicago] route.

BIO Tagging

- Si usano i tag **B**, **I**, **O**:
 - **B**: *Begin*, token che inizia uno *span* di entità.
 - **I**: *Inside*, token interno a uno *span*.
 - **O**: *Outside*, token esterno a qualsiasi *span*.
- Numero di tag (con n tipi di entità):
 $1 \text{ tag O} + n \text{ tag B} + n \text{ tag I} = 2n+1 \text{ tag totali.}$

• *Adesso abbiamo un tag per token!!!*

Words	BIO Label
Jane	B-PER
Villanueva	I-PER
of	O
United	B-ORG
Airlines	I-ORG
Holding	I-ORG
discussed	O
the	O
Chicago	B-LOC
route	O
.	O

BIO Tagging variants: IO and BIOES

Words	IO Label	BIO Label	BIOES Label
Jane	I-PER	B-PER	B-PER
Villanueva	I-PER	I-PER	E-PER
of	O	O	O
United	I-ORG	B-ORG	B-ORG
Airlines	I-ORG	I-ORG	I-ORG
Holding	I-ORG	I-ORG	E-ORG
discussed	O	O	O
the	O	O	O
Chicago	I-LOC	B-LOC	S-LOC
route	O	O	O
.	O	O	O

Guardiamo un modello funzionante su [HuggingFace](#) !!



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Standard algorithms for NER/POS tagging

- Algoritmi standard per NER/POS tagging:
 - Hidden Markov Models
 - Conditional Random Fields (CRF)
 - Modelli neurali per sequenze (RNNs or Transformers)
 - Large Language Models finetuned (come BERT)

Standard algorithms for NER/POS tagging

- Algoritmi standard per NER/POS tagging:
- Tutti richiedono un *training set* etichettato a mano e raggiungono performance simili (97% in inglese).
- Sfruttano le fonti di informazione già viste:
 - HMMs and CRFs con feature create dall'uomo
 - Neural Language Model tramite *representation learning*

HMM

- Si parte *dall'assunzione di Markov* per i bigrammi:


$$P(w_i \mid w_1, w_2, \dots, w_{i-1}) = P(w_i \mid w_{i-1})$$

- L'assunzione di Markov semplifica un modello che descrive la probabilità che un sistema stocastico si trovi in un certo stato, dopo aver attraversato una serie di stati e cioè una

catena di Markov

HMM

- Catena di Markov



$$Q = q_1 q_2 \dots q_N$$

a set of N states

$$A = a_{11} a_{12} \dots a_{N1} \dots a_{NN}$$

a **transition probability matrix** A , each a_{ij} representing the probability of moving from state i to state j , s.t. $\sum_{j=1}^n a_{ij} = 1 \quad \forall i$

$$\pi = \pi_1, \pi_2, \dots, \pi_N$$

an **initial probability distribution** over states. π_i is the probability that the Markov chain will start in state i . Some states j may have $\pi_j = 0$, meaning that they cannot be initial states. Also, $\sum_{i=1}^n \pi_i = 1$

HMM

- Un *Hidden Markov Model* usa una catena di Markov per stimare la probabilità di una serie di *eventi nascosti* (gli *stati*, cioè i tag POS) a partire da una serie di *osservazioni* (le *parole*).

HMM

$Q = q_1 q_2 \dots q_N$	a set of N states
$A = a_{11} \dots a_{ij} \dots a_{NN}$	a transition probability matrix A , each a_{ij} representing the probability of moving from state i to state j , s.t. $\sum_{j=1}^N a_{ij} = 1 \quad \forall i$
$O = o_1 o_2 \dots o_T$	a sequence of T observations , each one drawn from a vocabulary $V = v_1, v_2, \dots, v_V$
$B = b_i(o_t)$	a sequence of observation likelihoods , also called emission probabilities , each expressing the probability of an observation o_t being generated from a state q_i
$\pi = \pi_1, \pi_2, \dots, \pi_N$	an initial probability distribution over states. π_i is the probability that the Markov chain will start in state i . Some states j may have $\pi_j = 0$, meaning that they cannot be initial states. Also, $\sum_{i=1}^n \pi_i = 1$

Markov Assumption: $P(q_i | q_1, \dots, q_{i-1}) = P(q_i | q_{i-1})$

→ HMM del primo ordine

Output Independence: $P(o_i | q_1, \dots, q_i, \dots, q_T, o_1, \dots, o_i, \dots, o_T) = P(o_i | q_i)$



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



HMM Tagger

$$P(t_i|t_{i-1}) = \frac{C(t_{i-1}, t_i)}{C(t_{i-1})}$$


Stima MLE della probabilità di transizione dei Tag (A)

$$P(w_i|t_i) = \frac{C(t_i, w_i)}{C(t_i)}$$

Stima MLE della probabilità di emissione dei Tag (B)

$P(will|MD)$: posto che il tag successivo è MD, quanto è probabile che osserviamo la parola «will»?

HMM Tagger



HMM Tagger

$$\hat{t}_{1:n} = \operatorname{argmax}_{t_1 \dots t_n} P(t_1 \dots t_n | w_1 \dots w_n)$$

$$\hat{t}_{1:n} = \operatorname{argmax}_{t_1 \dots t_n} P(w_1 \dots w_n | t_1 \dots t_n) P(t_1 \dots t_n)$$

$$P(w_1 \dots w_n | t_1 \dots t_n) \approx \prod_{i=1}^n P(w_i | t_i)$$

$$P(t_1 \dots t_n) \approx \prod_{i=1}^n P(t_i | t_{i-1})$$

$$\hat{t}_{1:n} = \operatorname{argmax}_{t_1 \dots t_n} P(t_1 \dots t_n | w_1 \dots w_n) \approx \operatorname{argmax}_{t_1 \dots t_n} \prod_{i=1}^n \overbrace{P(w_i | t_i)}^{\text{emission transition}} \overbrace{P(t_i | t_{i-1})}$$

Il problema (una stima MLE)


Applichiamo la regola di Bayes scartando l'evidenza

$$P(w_1, \dots, w_n)$$

Indipendenza statistica dell'output

Usiamo i bigrammi

HMM Tagger



Algoritmo di Viterbi:

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) P(t_j | t_i) P(w_t | t_j) \quad 1 \leq j \leq N, 1 < t \leq T$$

CRF (Conditional Random Fields)

- Sarebbe utile poter considerare *feature* arbitrarie, cosa che gli HMM non gestiscono bene.
 - Parole sconosciute nel POS tagging
 - Nuovi verbi e nomi propri o comuni
 - Regole di morfologia (i.e. *-ed* → VBD oppure VBN)
 - ...

CRF

- Sarebbe utile poter considerare *feature* arbitrarie, cosa che gli HMM non gestiscono bene.
 - Gli HMM sono modelli generativi e richiedono il pre-calcolo di molte probabilità.
 - Bisogna ricalcolare le probabilità per l'aggiunta di una sola feature
- I ***modelli discriminativi***, come i CRF, gestiscono meglio vettori di *feature* lunghi.

CRF

- Un CRF impara a predire globalmente la sequenza di tag più probabile $\hat{Y}$ tra tutte le possibili sequenze di tag $\mathcal{Y}$ data una sequenza di input X

$$\hat{Y} = \operatorname{argmax}_{Y \in \mathcal{Y}} P(Y|X)$$

- Fa uso di una regressione logistica multinomiale (cioè su molte classi)

(Linear chain) CRF

Softmax

Dipende solo da X: non influisce su argmax

$$p(Y|X) = \frac{\exp \left(\sum_{k=1}^K w_k F_k(X, Y) \right)}{\sum_{Y' \in \mathcal{Y}} \exp \left(\sum_{k=1}^K w_k F_k(X, Y') \right)} = \frac{1}{Z(X)} \exp \left(\sum_{k=1}^K w_k F_k(X, Y) \right)$$

Feature globale

$$F_k(X, Y) = \sum_{i=1}^n f_k(y_{i-1}, y_i, X, i)$$

CRF

- Le feature locali dipendono solo dalla coppia di tag (y_i, y_{i-1}) dalla posizione i e dalla frase X

$$f_k(y_{i-1}, y_i, X, i)$$

$$\mathbb{1}\{x_i = \textit{the}, y_i = \text{DET}\}$$

$$\mathbb{1}\{y_i = \text{PROPN}, x_{i+1} = \textit{Street}, y_{i-1} = \text{NUM}\}$$

$$\mathbb{1}\{y_i = \text{VERB}, y_{i-1} = \text{AUX}\}$$

*Regole binarie:
1 se la regola vale
0 altrimenti*

CRF

- Le *feature* possono essere definite tramite *feature templates*, ovvero specifiche astratte.

$$\langle y_i, x_i \rangle, \langle y_i, y_{i-1} \rangle, \langle y_i, x_{i-1}, x_{i+2} \rangle$$

Janet/NNP will/MD back/VB the/DT bill/NN

$\langle \text{VB}, \text{back} \rangle, \langle \text{VB}, \text{MD} \rangle, \langle \text{VB}, \text{will}, \text{bill} \rangle$

CRF

- Si possono usare anche *feature* morfologiche e di *word-shape*:

- Prefissi, suffissi.
- Forma della parola

well-dressed

$\text{prefix}(x_i) = w$

$\text{prefix}(x_i) = we$

$\text{suffix}(x_i) = ed$

$\text{suffix}(x_i) = d$

$\text{word-shape}(x_i) = \text{xxxx-xxxxxxx}$

$\text{short-word-shape}(x_i) = \text{x-x}$

CRF

- Feature tipiche in un NER

identity of w_i , identity of neighboring words
embeddings for w_i , embeddings for neighboring words
part of speech of w_i , part of speech of neighboring words
presence of w_i in a **gazetteer**
 w_i contains a particular prefix (from all prefixes of length ≤ 4)
 w_i contains a particular suffix (from all suffixes of length ≤ 4)
word shape of w_i , word shape of neighboring words
short word shape of w_i , short word shape of neighboring words
gazetteer features

Una lista di nomi geografici

CRF

Words	POS	Short shape	Gazetteer	BIO Label
Jane	NNP	Xx	0	B-PER
Villanueva	NNP	Xx	1	I-PER
of	IN	x	0	O
United	NNP	Xx	0	B-ORG
Airlines	NNP	Xx	0	I-ORG
Holding	NNP	Xx	0	I-ORG
discussed	VBD	x	0	O
the	DT	x	0	O
Chicago	NNP	Xx	1	B-LOC
route	NN	x	0	O
.	.	.	0	O

Tutte le feature sono binarie

CRF

- **Training:** si usa lo *Stochastic Gradient Descent* con *Cross-Entropy Loss*.
 - Si usa la regolarizzazione
- **Inferenza:** si usa l'Algoritmo di Viterbi, modificato per includere il peso delle *feature* del CRF che vengono sommate ad ogni passo

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) + \sum_{k=1}^K w_k f_k(y_{t-1}, y_t, X, t) \quad 1 \leq j \leq N, 1 < t \leq T$$