



**Università
degli Studi
di Palermo**



Prompting e Model Alignment

CORSO DI NATURAL LANGUAGE PROCESSING (ELABORAZIONE DEL LINGUAGGIO NATURALE)

a.a. 2025/2026

Prof. Roberto Pirrone

Overview

-  Prompting
-  Model Alignment
-  Instruction Tuning
-  Chain-of-Thought Prompting
-  Automatic Prompt Optimization
-  Reinforcement Learning with Human Feedback
-  Direct Preference Optimization

Prompting

- Prompt: istruzione data in input ad un LLM.
 - La stringa del prompt dell'utente viene passata al LLM, che genera in modo iterativo token condizionati dal prompt.
 - Il prompt crea un contesto che guida gli LLM a generare output utili per raggiungere un obiettivo dell'utente.
- Prompt Engineering: il processo per trovare prompt efficaci per un determinato task

Prompting

Hotel Review Completions

Did not like the service that I was provided, when I entered the hotel. I also did not like the area, in which the hotel was located. Too much noise and events going on for me to feel relaxed.

Testo di condizionamento, da cui vogliamo eseguire un task

Prompting

Hotel Review Completions

Did not like the service that I was provided, when I entered the hotel. I also did not like the area, in which the hotel was located. Too much noise and events going on for me to feel relaxed. In short our stay was

Prompt per
l'analisi del
sentiment

Prompting

Hotel Review Completions

Did not like the service that I was provided, when I entered the hotel. I also did not like the area, in which the hotel was located. Too much noise and events going on for me to feel relaxed. In short our stay was

... not a pleasant one. The staff at the front desk were not welcoming or friendly, and seemed disinterested in providing good customer service.

... uncomfortable and not worth the price we paid. We will not be returning to this hotel.

Il testo
negativo nel
prompt
condiziona il
sentiment.

Prompting

- I prompt possono essere usati per una grande varietà di task
- Summarization
- Translation
- (Fine-grained) sentiment analysis
- ...

Template

- Se vogliamo risolvere un task, non vogliamo dover creare un nuovo prompt ogni volta che lo facciamo: possiamo usare i template

Basic Prompt Templates

Summarization	<code>{input} ; tldr;</code>
Translation	<code>{input} ; translate to French:</code>
Sentiment	<code>{input}; Overall, it was</code>
Fine-Grained-Sentiment	<code>{input}; What aspects were important in this review?</code>

Template

- I prompt (e anche i template) devono essere progettati in modo non ambiguo, in modo che qualsiasi continuazione ragionevole raggiunga il task desiderato.

A prompt consisting of a review plus an incomplete statement

Human: Do you think that “input” has negative or positive sentiment?

Choices:

(P) Positive

(N) Negative

Assistant: I believe the best answer is: (

Template

LLM Outputs for Basic Prompts

Original Review (\$INPUT)	Did not like the service that I was provided, when I entered the hotel. I also did not like the area, in which the hotel was located. Too much noise and events going on for me to feel relax and away from the city life.
Sentiment	Prompt: \$INPUT + In short, our stay was Output: not enjoyable
Fine-grained Sentiment	Prompt: \$INPUT + These aspects were important to the reviewer: Output: 1. Poor service 2. Unpleasant location 3. Noisy and busy area
Summarization	Prompt: \$INPUT + tl;dr Output: I had a bad experience with the hotel's service and the location was loud and busy.
Translation	Prompt: \$INPUT + Translate this to French Output: Je n'ai pas aimé le service qui m'a été offert lorsque je suis entré dans l'hôtel. Je n'ai également pas aimé la zone dans laquelle se trouvait l'hôtel. Trop de bruit et d'événements pour que je me sente détendu et loin de la vie citadine.

Prompting usando i template

1. Per un dato task, sviluppare un template specifico per il task che abbia un parametro libero per l'input testuale.
2. Dato quell'input e il template specifico per il task, l'input viene utilizzato per istanziare un prompt compilato che viene quindi passato a un LLM pretrained.
3. Viene quindi utilizzata la decodifica autoregressiva per generare una sequenza di token di uscita.
4. La risposta al task può coincidere con l'output del modello oppure può essere estratta da quest'ultimo.

Few-shot prompting

- Migliorare un prompt includendo alcuni esempi etichettati nel prompt template (dimostrazioni).
- Al contrario, lo *zero-shot prompting* utilizza prompt che non contengono alcun esempio etichettato.
- Possiamo avere zero- one- n- shot prompting o, in generale, few-shot prompting

Few-shot prompting

Definition: This task is about writing a correct answer for the reading comprehension task. Based on the information provided in a given passage, you should identify the shortest continuous text span from the passage that serves as an answer to the given question. Avoid answers that are incorrect or provides incomplete justification for the question.

Passage: Beyoncé Giselle Knowles-Carter (born September 4, 1981) is an American singer, songwriter, record producer and actress. Born and raised in Houston, Texas, she performed in various singing and dancing competitions as a child, and rose to fame in the late 1990s as lead singer of R&B girl-group Destiny's Child. Managed by her father, Mathew Knowles, the group became one of the world's best-selling girl groups of all time. Their hiatus saw the release of Beyoncé's debut album, *Dangerously in Love* (2003), which established her as a solo artist worldwide, earned five Grammy Awards and featured the Billboard Hot 100 number-one singles "Crazy in Love" and "Baby Boy".

Examples:

Q: In what city and state did Beyoncé grow up?

A: Houston, Texas

Q: What areas did Beyoncé compete in when she was growing up?

A: singing and dancing

Q: When did Beyoncé release *Dangerously in Love*?

A: 2003

Q: When did Beyoncé start becoming popular?

A:

Few-shot prompting

Quanti esempi?

- Non troppi: un numero casuale e piccolo.
- I maggiori guadagni di *performance* tendono a provenire dal primo esempio di *training* e diminuiscono per quelli successivi.
- Sono utili a dimostrare il *task* al LLM insieme al formato della sequenza.

Few-shot prompting

Come selezionare gli esempi?

- Automaticamente
 - Selezionate i top-T embeddings più simili nel training set all'embedding dell'esempio corrente.
- Programmaticamente
 - Utilizzare una misura di performance del task per selezionare gli esempi che la massimizzano.

In-Context Learning


- In generale i prompt con o senza esempi, possono essere visti come una sorta di processo di *learning*
 - Più un modello *legge* il prompt, più tende a migliorare nella previsione dei tokens successivi.
 - L'informazione nel contesto aiuta a dare al modello maggiori capacità predittive.
- Questa capacità di apprendimento dei LLM generativi tramite prompt è chiamata *in-context learning*.

Induction head

- Diverse ipotesi sono state effettuate circa il funzionamento del in-context learning.
- In particolare, le *induction head* sono delle particolari zone della rete costituite da alcune delle attention head che assumono un ruolo particolare nell'aiutare il modello a fare previsioni, basandosi sul riconoscimento di pattern del tipo:

$$\{A, B, \dots, A\} \rightarrow B$$

Induction head




- Le *previous token head* sono attention head responsabili di prestare attenzione al token precedente e copiarlo nel residual stream del token a cui si presta attenzione.
- Le induction head eseguono quindi un'operazione di match-and-copy, cercando una corrispondenza tra una query derivata dal token corrente e una key derivata dall'output della token head precedente.

Induction heads

Percorso verde
Matching


Il token corrente **Q**
corrisponde fortemente
al **K** token, il cui residual
stream incorpora il token
corrente



Induction heads

Percorso blu
Copying

La V del matched token viene spostata (copied) nell'output per il token corrente



Model Alignment

- Il potere del in-context learning è limitato
 - Spesso, la tendenza autoregressiva del modello lo spinge ad ingorare il condizionamento datogli dal prompt.
 - I LLM pretrained generano testi che possono essere dannosi (falsi, unsafe, toxic, ...)
- Model alignment: metodi progettati per adattare meglio i LLM alle esigenze umane per generare testo utile e non dannoso.


Model Alignment

- Due strategie principali per il model alignment:
 - *Instruction tuning* (Supervised Fine Tuning - SFT): i modelli sono sottoposti a finetuning su un corpus di istruzioni e domande con le loro risposte corrispondenti.
 - *Preference alignment*: un modello separato viene addestrato per decidere quanto una risposta candidata si allinea alle preferenze umane; questo modello viene quindi utilizzato per il fine tuning del base model.
 - Il Reinforcement Learning from Human Feedback (RLHF), è la più nota tecnica di preference alignment

Instruction tuning

- Instruction tuning (instruction fine tuning, instruct, IT) è un metodo per rendere un LLM migliore nel seguire le istruzioni per una serie di tasks.
- Un LLM pretrained viene sottoposto a finetuning su un corpus di istruzioni e risposte utilizzando sempre la language modeling loss (CE Loss).
- Il modello risultante non solo apprende quei tasks, ma si impegna anche in una forma di meta-learning: migliora la sua capacità di seguire le istruzioni in generale.

Instruction tuning



Istruzioni come dati di training

- L'Instruction tuning è in realtà una procedura di training.
- Di conseguenza, devono essere sviluppati appositamente corpora di istruzioni etichettate.
- Esistono diversi corpora scritti da umani.
 - Un task che richiede molto tempo.

Istruzioni come dati di training

- Aya: 503 milioni di istruzioni, 114 lingue, 12 tasks
 - Q/A, summarization, translation, paraphrasing, sentiment analysis, natural language inference, ...
- Istruzioni scritte da 3000 fluent speakers in 65 lingue

Istruzioni come dati di training

- SuperNatural Instructions: 12 milioni di esempi da 1600 tasks.
- Flan 2022: 15 milioni di esempi da 1836 tasks.
- OPT-IML: 18 milioni di esempi da 2000 tasks

Istruzioni come dati di training

- Come scrivere data set di istruzioni di alta qualità?
- Sfruttiamo la grandissima quantità di dati curati sviluppati nel corso degli anni per qualsiasi task.
- Li trasformiamo automaticamente in istruzioni utilizzando template.

Istruzioni come dati di training

- Come scrivere data set di istruzioni di alta qualità?

Few-Shot Learning for QA

Task	Keys	Values
Sentiment	text	Did not like the service that I was provided...
	label	0
NLI	text	It sounds like a great plot, the actors are first grade, and...
	label	0
	premise	No weapons of mass destruction found in Iraq yet.
	hypothesis	Weapons of mass destruction found in Iraq.
	label	2
	premise	Jimmy Smith... played college football at University of Colorado.
	hypothesis	The University of Colorado has a college football team.
	label	0
Extractive Q/A	context	Beyoncé Giselle Knowles-Carter is an American singer...
	question	When did Beyonce start becoming popular?
	answers	{ text: ['in the late 1990s'], answer_start: 269 }

Istruzioni come dati di training

- Come scrivere data set di istruzioni di alta qualità?

Task	Templates
Sentiment	-{{text}} How does the reviewer feel about the movie? -The following movie review expresses what sentiment? {{text}} -{{text}} Did the reviewer enjoy the movie?
Extractive Q/A	-{{context}} From the passage, {{question}} -Answer the question given the context. Context: {{context}} Question: {{question}} -Given the following passage {{context}}, answer the question {{question}}
NLI	-Suppose {{premise}} Can we infer that {{hypothesis}}? Yes, no, or maybe? -{{premise}} Based on the previous passage, is it true that {{hypothesis}}? Yes, no, or maybe? -Given {{premise}} Should we assume that {{hypothesis}} is true? Yes,no, or maybe?

Istruzioni come dati di training

- Come scrivere data set di istruzioni di alta qualità?
- Molti data set curati sono generati da crowdworkers in base a linee guida di annotazione scritte con cura.
- Un'idea potrebbe essere quella di eseguire prompt per interrogare LLM basandosi su queste linee guida.

Istruzioni come dati di training

- Come scrivere data set di istruzioni di alta qualità?

Sample Extended Instruction

- **Definition:** This task involves creating answers to complex questions, from a given passage. Answering these questions, typically involve understanding multiple sentences. Make sure that your answer has the same type as the "answer type" mentioned in input. The provided "answer type" can be of any of the following types: "span", "date", "number". A "span" answer is a continuous phrase taken directly from the passage or question. You can directly copy-paste the text from the passage or the question for span type answers. If you find multiple spans, please add them all as a comma separated list. Please restrict each span to five words. A "number" type answer can include a digit specifying an actual value. For "date" type answers, use DD MM YYYY format e.g. 11 Jan 1992. If full date is not available in the passage you can write partial date such as 1992 or Jan 1992.
- **Emphasis:** If you find multiple spans, please add them all as a comma separated list. Please restrict each span to five words.
- **Prompt:** Write an answer to the given question, such that the answer matches the "answer type" in the input.
Passage: { passage }
Question: { question }

Istruzioni come dati di training

- Come scrivere data set di istruzioni di alta qualità?
- Gli LLM possono essere utilizzati in ogni fase del processo di trasformazione automatica.
- Ad esempio, possono essere utilizzati per parafrasare le istruzioni, aumentando così la dimensione del corpus (data agumentation).

Valutazione dei modelli IT

- L'obiettivo dell'instruction tuning non è imparare un singolo task, ma piuttosto imparare a seguire le istruzioni in generale.
- Valutare i metodi di instruction-tuning significa valutare quanto bene un modello addestrato con istruzioni si comporta su tasks nuovi.

Valutazione dei modelli IT

Come farlo? Approccio Leave-one-out

- Rimuoviamo un intero cluster di task dal corpus e li usiamo per il testing.
- Molti task in un corpus sono simili e spesso si sovrappongono.
- Le stesse metriche di valutazione possono essere utilizzate per tutti i task nel test set.

Chain-of-Thought Prompting

- Chain-of-Thought prompting (CoT) è una tecnica per migliorare la performance su task di reasoning difficili in cui i LLM tendono a fallire.
- Le persone risolvono compiti complessi suddividendoli in step.
- L'istruzione nel prompt incoraggerà i LLM a suddividerli allo stesso modo.

Chain-of-Thought Prompting

- Ciascun esempio nel few-shot prompting è arricchito con del testo che spiega alcuni passaggi di ragionamento, generando una dimostrazione.
- L'obiettivo è indurre il language model sia a produrre dei passaggi di ragionamento analoghi per il problema che si sta risolvendo sia a generare la risposta corretta come output.

Chain-of-Thought Prompting

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?



A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

Chain-of-Thought Prompting



Automatic Prompt Optimization

- Dato un prompt per un task, i metodi di Automatic Prompt Optimization cercano prompt che possano fornire performance migliori.
- Questo approccio può essere rivisto come una ricerca iterativa nello spazio dei prompt.

Automatic Prompt Optimization

Come algoritmo di ricerca abbiamo bisogno di:

- Uno stato iniziale: uno o più prompt iniziali generati dall'uomo o dalla macchina.
- Una metrica di scoring: un metodo per valutare quanto bene il prompt si comporta sul task.
- Un metodo di espansione: un metodo per generare varianti del prompt.

Automatic Prompt Optimization

- Beam search

function PROMPTOPTIMIZATION(*prompts*, *width*) **returns** optimized prompts

active $\leftarrow$ *prompts* ; Add initial set of candidate prompts to agenda

repeat until done

frontier $\leftarrow$ *foo*

children $\leftarrow$ EXPAND(*c*) ; Expand each candidate prompt

foreach *c* $\in$ *children*

frontier $\leftarrow$ ADDTOBEAM(*c*, *frontier*, *w*) ; apply it, creating a new state

active $\leftarrow$ *frontier*

return

function ADDTOBEAM(*state*, *agenda*, *width*) **returns** updated agenda

if LENGTH(*agenda*) < *width* **then**

agenda $\leftarrow$ INSERT(*state*, *agenda*)

else if SCORE(*state*) > SCORE(WORSTOF(*agenda*))

agenda $\leftarrow$ REMOVE(WORSTOF(*agenda*))

agenda $\leftarrow$ INSERT(*state*, *agenda*)

return *agenda*

Automatic Prompt Optimization

- Candidate scoring
 - Cruciale per il costo computazionale
 - L'output del LLM è valutato rispetto all'etichetta del training set usando una metrica appropriata per il task
 - I prompt candidati sono mescolati con i campioni del training set

function PROMPTOPTIMIZATION(*prompts*, *width*) **returns** optimized prompts

active $\leftarrow$ *prompts* ; Add initial set of candidate prompts to agenda

repeat until done

frontier $\leftarrow$ *foo*

children $\leftarrow$ EXPAND(*c*) ; Expand each candidate prompt

foreach *c* $\in$ *children*

frontier $\leftarrow$ ADDTOBEAM(*c*, *frontier*, *w*) ; apply it, creating a new state

active $\leftarrow$ *frontier*

return

function ADDTOBEAM(*state*, *agenda*, *width*) **returns** updated agenda

if LENGTH(*agenda*) < *width* **then**

agenda $\leftarrow$ INSERT(*state*, *agenda*)

else if SCORE(*state*) > SCORE(WORSTOF(*agenda*))

agenda $\leftarrow$ REMOVE(WORSTOF(*agenda*))

agenda $\leftarrow$ INSERT(*state*, *agenda*)

return *agenda*

Automatic Prompt Optimization

- Espansione del prompt
 - Varianti di un dato prompt per creare un set di prompt vicini che possano migliorare le performance rispetto all'originale
- In genere si usa la parafrasi

```
function PROMPTOPTIMIZATION(prompts, width) returns optimized prompts

active  $\leftarrow$  prompts ; Add initial set of candidate prompts to agenda
repeat until done
  frontier  $\leftarrow$  foo
  children  $\leftarrow$  EXPAND(c) ; Expand each candidate prompt
  foreach c  $\in$  children
    frontier  $\leftarrow$  ADDTOBEAM(c, frontier, w) ; apply it, creating a new state
  active  $\leftarrow$  frontier
return

function ADDTOBEAM(state, agenda, width) returns updated agenda

if LENGTH(agenda) < width then
  agenda  $\leftarrow$  INSERT(state, agenda)
else if SCORE(state) > SCORE(WORSTOF(agenda))
  agenda  $\leftarrow$  REMOVE(WORSTOF(agenda))
  agenda  $\leftarrow$  INSERT(state, agenda)
return agenda
```

Automatic Prompt Optimization

- Espansione del prompt
 - Si utilizza un LLM per generare la parafrasi

Prompting for a Variant

Generate a variation of the following instruction while keeping the semantic meaning.

Input: {INSTRUCTION}

Output: {COMPLETE}

Automatic Prompt Optimization

- Informed search

1. Esegui il prompt su un campione del training set.
2. Identifica gli esempi in cui il prompt fallisce.
3. Chiedi ad un LLM di produrre una critica del prompt alla luce degli esempi falliti.
4. Fornisci la critica a un LLM e chiedigli di generare un prompt migliorato per risolvere la critica.

Automatic Prompt Optimization

Critiquing Prompt

I'm trying to write a zero-shot classifier prompt.
My current prompt is: {prompt}
But this prompt gets the following examples wrong:
{error_string}
Give {num_feedbacks} reasons why the prompt could have
gotten these examples wrong.

Prompt Improvement Prompt

I'm trying to write a zero-shot classifier. My current prompt is:
{prompt}
But it gets the following examples wrong: {error_str}

Based on these examples the problem with this prompt is that {gradient}.
Based on the above information, I wrote {steps_per_gradient} different
improved prompts. Each prompt is wrapped with <START> and <END>.


The {steps_per_gradient} new prompts are:

RLHF


- *Reinforcement Learning with Human Feedback* (RLHF) sfrutta degli addestratori umani per migliorare le performance del modello.
 - Gli addestratori classificano le risposte fornite dal modello in una precedente conversazione
 - I rank ottenuti sono usati per creare un modello di reward utilizzato nelle iterazioni dell'algoritmo di reinforcement learning di tipo *Proximal Policy Optimization* (PPO)

RLHF


STEP1:
Supervised Fine
Tune




STEP2:
Reward Model
Training



STEP3:
Reinforcement
Learning



RLHF



Proximal Policy Optimization

- Proximal Policy Optimization (PPO) è un algoritmo di RL il cui scopo è quello di migliorare iterativamente le policy del modello mantenendo la stabilità
- Questo metodo ottimizza direttamente i parametri del modello basandosi sul feedback umano sugli output generati.
- Ha lo scopo di apprendere una policy che massimizza la soddisfazione umana.

Proximal Policy Optimization

1. Policy Initialization: Inizializza una policy, una funzione che determina la strategia per cui ad un dato input è associato un determinato output.
2. Ripeti fino a convergenza:
 1. Data Collection: Collezione dati interagendo con l'ambiente usando la policy corrente.
 2. Estimate Advantage: Calcola una «funzione di vantaggio», che misura quanto un'azione è migliore rispetto all'azione media.
 3. Update Policy: Aggiorna la policy tramite gradient ascent, usando una funzione di clipping per evitare che la nuova policy sia troppo diversa rispetto alla precedente.

Proximal Policy Optimization

- PPO è stabile, robusto e computazionalmente efficiente
 - I cambiamenti policy sono controllati.
 - È in grado di gestire scenari di reward complessi.
 - Ottimo per task complessi che richiedono Iterative Learning, come generazione di codice e pianificazioni a lungo termine.
 - Buono per lo sviluppo di modelli su larga scala (i.e. modelli GPT).

Direct Preference Optimization

- *Direct Preference Optimization* (DPO) è un approccio migliorato per effettuare l'allineamento dei modelli per gli LLM
- Ottimizza direttamente i parametri del modello basandosi sulle preferenze umane.
- Elimina la necessità di addestrare un modello di reward e non necessita di una fase estensiva di tuning degli iperparametri.

Direct Preference Optimization

1. Data Collection: Collezione di un data set di output generati dal modello e delle preferenze umane corrispondenti, ad es. rankings, ratings, o comparazioni binarie
2. Inizializzazione del modello con parametri randomici.
3. Ripeti fino a convergenza
 1. Preference Modeling: Sviluppare una funzione di loss che misura la discrepanza fra gli output del modello e le preferenze umane.
 2. Parameter Update: Per minimizzare la funzione di loss, aggiornare i parametri del modello usando la discesa lungo il gradiente o analoghi algoritmi di ottimizzazione.

Direct Preference Optimization

- DPO esegue un allineamento veloce e efficace.
- È molto leggero e riesce a mitigare il rischio di ereditare bias presenti nel training set
 - Buono per task semplici
 - Richiede poche risorse computazionali
 - Consente un aggiornamento frequente del modello rispetto alle preferenze dell'utente

PPO vs DPO


Reinforcement Learning from Human Feedback (RLHF)

x: "write me a poem about
the history of jazz"



preference data

maximum
likelihood



Direct Preference Optimization (DPO)

x: "write me a poem about
the history of jazz"



preference data

maximum
likelihood



PPO vs DPO

PPO

- ✓ Per task complessi che richiedono un apprendimento iterativo
- ✓ Per casi in cui è presente una gestione strutturata del reward
- ✓ Per casi in cui è richiesta stabilità e robustezza
- ✓ Pianificazione strategica a lungo termine
- ✓ Implementazioni a grande scala

PPO vs DPO

DPO

- ✓ Quando i dati sono molto allineati alle preferenze
- ✓ Per task più semplici e ben definiti; non serve la complessità del RL
- ✓ Quando è richiesta una più rapida adattabilità e il feedback umano è richiesto
- ✓ Nei casi in cui ci sono risorse computazionali limitate