



**Università
degli Studi
di Palermo**



Task Generativi e Valutazione

CORSO DI NATURAL LANGUAGE PROCESSING (ELABORAZIONE DEL LINGUAGGIO NATURALE)

a.a. 2025/2026

Prof. Roberto Pirrone

Overview

Task generativi

-  Machine Translation

-  Text Classification

-  Question Answering

Valutazione

-  Metriche di valutazione automatica

-  LLM as a judge

Machine Translation

- Il task di Machine Translation (MT), si riferisce ai compiti di traduzione automatica da parte di modelli encoder-decoder e decoder-only
- Le lingue hanno alcune caratteristiche universali (ci sono parole per riferirsi alle persone, al mangiare, all'essere educati, ecc.)

Machine Translation

Tuttavia, presentano molte differenze:


- Ordinamento delle parole
 - Subject-Verb-Object, Subject-Object-Verb, Verb-subject-Object e uso di preposizioni o postposizioni
- Divergenze lessicali
 - Più parole (sinonimi) per esprimere lo stesso concetto in una lingua

Machine Translation


Tuttavia, presentano molte differenze:

- Tipologie morfologiche
 - Lingue basate su morfemi isolati o fusi
- Densità referenziale
 - Elementi che si tendono ad omettere, vedi i pronomi
«I talked to Juliet yesterday. She was very sad.»
«Ieri ho parlato con Juliet. Era molto triste.»

Machine Translation



Machine Translation



Teacher forcing con loss:

$$L_{CE}(\hat{\mathbf{y}}_t, \mathbf{y}_t) = -\log \hat{\mathbf{y}}_t[w_{t+1}]$$

Layer extra che implementa la cross attention sull'input dell'encoder e il testo generato dal decoder

Al layer ℓ :

$$\mathbf{Q} = \mathbf{H}^{dec[\ell-1]} \mathbf{W}^Q; \quad \mathbf{K} = \mathbf{H}^{enc} \mathbf{W}^K; \quad \mathbf{V} = \mathbf{H}^{enc} \mathbf{W}^V$$


$$\text{CrossAttention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V}$$

Machine Translation

- Il decoding con la greedy search è una soluzione localmente ottimale nello spazio delle soluzioni
- È necessario implementare strategie di ricerca che siano globalmente ottimali
- L'unico algoritmo che garantisce una soluzione ottimale è la ricerca esaustiva ma è impraticabile (V^T possibilità)

Soluzione ottima: «ok ok </s>»

$$P = 0.4 * 0.7 * 1 = 0.28$$




Machine Translation

- Il decoding con la greedy search è una soluzione localmente ottimale nello spazio delle soluzioni
- È necessario implementare strategie di ricerca che siano globalmente ottimali
- L'unico algoritmo che garantisce una soluzione ottimale è la ricerca esaustiva ma è impraticabile (V^T possibilità)

Soluzione greedy: «yes yes </s>»

$$P = 0.5 * 0.4 * 1 = 0.20$$



Beam Search

- Il decoding è ottenuto mantenendo i migliori k token ad ogni passo
 1. Per ciascun step t_i nel path fino al token END:
 - a) Per ciascuna delle k ipotesi migliori ottenute a quel punto (i.e. le k migliori sequenze generate)
 1. Calcola le probabilità di tutti i token del vocabolario a partire dall'ipotesi corrente $P(y_i|x, y_{<i})$
 - b) Mantieni le sole top k ipotesi con probabilità migliore
 2. Rimuovi le sequenze complete e imposta $k = k - 1$
 3. Ripeti fino a $k == 0$

function BEAMDECODE($c, beam_width$) **returns** best paths

$y_0, h_0 \leftarrow ()$

$path \leftarrow ()$

$complete_paths \leftarrow ()$

$state \leftarrow (c, y_0, h_0, path)$;initial state

$frontier \leftarrow \langle state \rangle$;initial frontier

while $frontier$ contains incomplete paths **and** $beamwidth > 0$

$extended_frontier \leftarrow \langle \rangle$

for each $state \in frontier$ **do**

$y \leftarrow \text{DECODE}(state)$

for each word $i \in \text{Vocabulary}$ **do**

$successor \leftarrow \text{NEWSTATE}(state, i, y_i)$

$extended_frontier \leftarrow \text{ADDTOBEAM}(successor, extended_frontier, beam_width)$

for each state in $extended_frontier$ **do**

if state is complete **do**

$complete_paths \leftarrow \text{APPEND}(complete_paths, state)$

$extended_frontier \leftarrow \text{REMOVE}(extended_frontier, state)$

$beam_width \leftarrow beam_width - 1$

$frontier \leftarrow extended_frontier$

return $completed_paths$

function NEWSTATE($state, word, word_prob$) **returns** new state

function ADDTOBEAM($state, frontier, width$) **returns** updated frontier

if LENGTH($frontier$) < $width$ **then**

$frontier \leftarrow \text{INSERT}(state, frontier)$

else if SCORE($state$) > SCORE(WORSTOF($frontier$))

$frontier \leftarrow \text{REMOVE}(\text{WORSTOF}(frontier))$

$frontier \leftarrow \text{INSERT}(state, frontier)$


return $frontier$

Beam Search


$k = 2$

Semplicemente
aggiungiamo a ciascun
step la log-probabilità per
il token selezionato

$$\begin{aligned}
 \text{score}(y) &= \log P(y|x) \\
 &= \log (P(y_1|x)P(y_2|y_1,x)P(y_3|y_1,y_2,x)...P(y_t|y_1,...,y_{t-1},x)) \\
 &= \sum_{i=1}^t \log P(y_i|y_1,...,y_{i-1},x)
 \end{aligned}$$



Beam Search



Beam Search

- Lo score ottenuto (le log-probabilità) devono essere normalizzate per le sequenze con diverse lunghezza
- La natura additiva dello score penalizza le sequenze lunghe, serve un fattore di normalizzazione

$$\textit{score}(y) = -\log P(y|x) = \frac{1}{T} \sum_{i=1}^t -\log P(y_i|y_1, \dots, y_{i-1}, x)$$

Minimum Bayes Risk decoding

- Il Minimum Bayes Risk (MBR) decoding è un'altra strategia di decoding che fa uso esplicito di una metrica di valutazione (util) per misurare la bontà della traduzione c con un set $\mathcal{Y}$ di traduzioni candidate:

$$\hat{y} = \operatorname{argmax}_{y \in \mathcal{Y}} \sum_{c \in \mathcal{Y}} \operatorname{util}(y, c)$$

- Dato l'insieme di tutte le possibili traduzioni, restringiamo ad un sottoinsieme di traduzioni candidate la cui correttezza viene misurata con un'apposita metrica.
 - Invece di scegliere la traduzione più probabile, scegliamo quella con l'errore più basso

Text Classification

- In ottica generativa, diversi task possono essere visti come task di classificazione
 - Sentence similarity
 - Document similarity
 - Text Classification
 - Sentiment Analysis
 - Fake News Detection
 - Hate Speech Detection
 - ...

Text Classification

Come posso fare text classification con i LLM?

- Prompting
- Post-processing sull'output generato dal modello
- Constraint decoding per forzare il modello a generare solo le possibili label
 - Outlines

Question Answering

- Nel Question Answering (QA) viene dato in input ai modelli una domanda e l'utente si aspetta una risposta.
- Diverse tipologie di QA
 - Extractive: dato un contesto individuare la risposta per la domanda dell'utente.
 - Da un testo individuare la sottosequenza con la risposta
 - Selezionare una delle possibili risposte (*Closed QA* o multi-choice)
 - Abstractive: generare una risposta da un contesto che risponde alla domanda (*Open QA*).

Question Answering

I sistemi di QA:

- Sono progettati per rispondere alla necessità dell'utente e poiché molte informazioni possono essere presenti nella domanda o nel testo associato, di fatto eseguono un compito analogo a quello dei search engines.

Question Answering

I sistemi di QA:

- Spesso si focalizzano su factoid questions, domande riguardanti informazioni o fatti, la cui risposta è costituita da testi semplici di breve-media lunghezza:
 - *Dove si trova il Museo del Louvre?*
 - *Da dove proviene l'energia in un'esplosione nucleare?*

Question Answering

- Il task di QA, anche nei casi di QA extractive, può essere demandato ad un LLM in forma puramente generativa

Q: Where is the Louvre Museum located? A:

- Il rischio di ottenere allucinazioni o risposte non allineate alla realtà dei fatti è alta
 - In questi casi si fa leva sulla conoscenza intrinseca dei modelli acquisita durante la fase di pre-training
- Potrebbe essere necessario fornire ulteriore conoscenza al modello, sistemi di Information Retrieval, RAG

Valutazione

- Il passaggio di valutazione è necessario nella maggior parte dei task generativi per stimare la bontà della risposta generata dal modello.
- È auspicabile avere a disposizione un corpus di frasi golden o reference con cui confrontare la risposta generata.
- Ma non sempre tale corpus è disponibile e bisogna utilizzare delle opportune tecniche di valutazione.

Valutazione

- Se non ci sono delle risposte golden di riferimento, è possibile provare a valutare il testo generato rispetto a due proprietà:
 - *Adequacy* o *Faithfulness* rispetto al significato del testo
 - *Fluency* rispetto alla struttura grammaticale
- Tipi di valutazione
 - Umana
 - Automatica
 - LLM as a judge

Valutazione umana

- La valutazione umana tramite annotatori (crowdworkers) può essere una soluzione.
 - Utile nei casi in cui manca una golden answer
 - Chiedere di fornire uno score numerico per faithfulness o altre proprietà
 - Effettuare un ranking delle risposte generate
 - Possono fornire valutazioni di alta qualità ma c'è un costo non indifferente

Valutazione automatica

- I metodi di valutazione automatica permettono di comparare una risposta generata (hypothesis) h con una o più frasi di reference r .
- Si possono valutare le somiglianze basandosi su
 - Character overlapping
 - Embeddings similarity
- Possono essere utilizzate per tutti i task generativi, *ma è necessario che ci sia almeno una reference.*

Valutazione automatica

- Character overlap
 - chrF
 - BLEU
 - ROUGE
 - METEOR
- Embeddings similarity
 - BERTScore

chrF

- Character F-score (chrF) si basa sull'intuizione che un buon sistema di MT produrrà del testo contenente caratteri e parole che compaiono anche nella traduzione umana della stessa frase
- chrF misura il grado di sovrapposizione fra la frase generata e una frase reference

chrF

- chrF è calcolata a partire da k , ovvero il numero di k -grams da considerare e calcola la media delle k precisions (chrP) e delle k recall (chrR) fra r e h e ne calcola la F1-score pesata con β .

chrP percentage of character 1-grams, 2-grams, ..., k -grams in the hypothesis that occur in the reference, averaged.

chrR percentage of character 1-grams, 2-grams,..., k -grams in the reference that occur in the hypothesis, averaged.

$$\text{chrF}\beta = (1 + \beta^2) \frac{\text{chrP} \cdot \text{chrR}}{\beta^2 \cdot \text{chrP} + \text{chrR}}$$

BLEU

- La *BiLingual Evaluation Understudy* (BLEU) è una metrica basata sulla precision dovuta alla sovrapposizione delle parole fra r e h .
- Dato un corpus di frasi candidate e references $H = \{h_i\}$ e $R = \{r_i\}$, BLEU è una funzione della n-gram word precision $p_n(H, R)$ rispetto a tutte le frasi reference, combinate rispetto a una Brevity Penalty (BP) calcolata sull'intero corpus.

BLEU

$$p_n(H, R) = \frac{\sum_i \sum_{s \in D_n^{(h_i)}} \min(C(s, h_i), \max_{r_j} C(s, r_j))}{\sum_{s \in D_n^{(h_i)}} C(s, h_i)}$$

$$\text{BLEU}(H, R) = \text{BP} \cdot \exp \left(\frac{1}{N} \sum_{n=1}^N \log p_n(H, R) \right)$$

- $D_n^{(h_i)}$ è il numero dei n-grams distinti in h_i
- N è il massimo n-gram considerato, tipicamente $N=4$

ROUGE

- *Recall-Oriented Understudy for Gisting Evaluation* (ROUGE) è un set di metriche dove è possibile misurare la sovrapposizione di n-grammi e calcolare precision, recall e F1 score.
- ROUGE-N: (tipicamente ROUGE-1 and ROUGE-2)

$$\text{Precision: } \frac{\# \text{ N-grams comuni}}{\# \text{ N-grams in } h}$$

$$\text{Recall: } \frac{\# \text{ N-grams comuni}}{\# \text{ N-grams in } r}$$

$$F1 = 2 \frac{P * R}{P + R}$$

ROUGE

- ROUGE-L variante in cui si va a ricercare la Longest Common Subsequence (LCS) fra h e r

$$\text{Precision: } \frac{\text{LCS}(h, r)}{\# \text{ 1-grams in } h}$$

$$\text{Recall: } \frac{\text{LCS}(h, r)}{\# \text{ 1-grams in } r}$$

$$F1 = 2 \frac{P * R}{P + R}$$

METEOR

- Le metriche basate su sovrapposizione di N-grams non sono ottimali nel caso di sinonimi o parafrasi.
- *Metric for Evaluation of Translation with Explicit Ordering* (METEOR) incorpora analogamente a BLEU e ROUGE il concetto di precision e recall basato su n-grammi, ma tiene in conto anche la sinonimia, lo stemming e le variazioni delle parole, nonché l'ordine delle parole.

METEOR


$$F_{\text{mean}} = \frac{10 P * R}{R + 9 * P}$$

$$\text{Penalty} = 0.5 * \frac{\# \text{ chunks}}{\# \text{ 1-grams matched}}$$

$$\text{Score} = F_{\text{mean}} * (1 - \text{Penalty})$$

BERTScore

- BERTScore, invece di paragonare gli n-grams e i token, sposta il task di comparazione nello spazio degli embeddings



LLM as a judge

- LLM as a judge è una tecnica di valutazione del testo generato da LLM in cui un *LLM esperto* viene interrogato per esprimere una valutazione circa l'output generato
- Gli LLM esperti sono gli LLM di grandi dimensioni quali GPT4, GPT5, Gemini Pro, Claude

LLM as a judge

$$\mathcal{E} \leftarrow P_{LLM}(x \oplus \mathcal{C})$$

- $\mathcal{E}$ valutazione ottenuta dal LLM (score, label)
- P_{LLM} funzione di probabilità associata al LLM giudice
- x input da valutare
- $\mathcal{C}$ contesto per la valutazione (prompt, template)
- $\oplus$ operatore che combina x e $\mathcal{C}$

LLM as a judge

- Template per una valutazione binaria

Is the sentence supported by the article?
Answer "Yes" or "No".

Article: {Article}
Sentence: {Sentence}

LLM as a judge

- Template per una comparazione binaria

Given a new article, which summary is better?
Answer "Summary 0" or "Summary 1".
You do not need to explain the reason.

Article: {Article}
Summary 0: {Summary_0}
Summary 1: {Summary_1}

LLM as a judge

- Template per una valutazione su scala di Likert

Evaluate the quality of summaries written for a news article. Rate each summary on four dimensions: {Dimension_1}, {Dimension_2}, {Dimension_3}, and {Dimension_4}. You should rate on a scale from 1 (worst) to 5 (best) .

Article: {Article}

Summary: {Summary}

LLM as a judge

Imagine you are a human annotator now. You will evaluate the quality of summaries written for a news article. **Please follow these steps:**

1. Carefully read the news article, and be aware of the information it contains.
2. Read the proposed summary.
3. Rate the summary on four dimensions: relevance, consistency, fluency, and coherence. You should rate on a scale from 1 (worst) to 5 (best).

Definitions are as follows:

Relevance: The rating measures how well the summary captures the key points of the article. Consider whether all and only the important aspects are contained in the summary.

Consistency: The rating measures whether the facts in the summary are consistent with the facts in the original article. Consider whether the summary does reproduce all facts accurately and does not make up untrue information.

Fluency: This rating measures the quality of individual sentences, whether they are well-written and grammatically correct. Consider the quality of individual sentences.

Coherence: The rating measures the quality of all sentences collectively, to fit together and sound natural. Consider the quality of the summary as a whole.

The article and the summary are given below:

Article: {Article}

Summary: {Summary}

Figure 5: The template for Likert scale scoring with step instructions (in red) and dimension definitions (in orange)


LLM as a judge

Summary	Paul Merson was brought on with only seven minutes remaining in his team's 0-0 draw with Burnley. Andros Townsend scored the Tottenham midfielder in the 89th minute. Paul Merson had another dig at Andros Townsend after his appearance. The midfielder had been brought on to the England squad last week. Click here for all the latest arsenal news."
Expert annotator	Relevance: 1.67 (2, 1, 2) Consistency (Faithfulness): 1.00 (1, 1, 1) Fluency: 3.00 (4, 2, 3) Coherence: 1.33 (2, 1, 1)
ChatGPT	Relevance: 2 Faithfulness: 2 Fluency: 2 Coherence: 2 Overall score: 2 This summary is not very relevant to the article as it only mentions a few details and leaves out important information. It is not very faithful as it misrepresents the article by suggesting that Andros Townsend scored in the Tottenham game, when in fact he was only brought on as a substitute. The fluency and coherence are also poor, with awkward phrasing and lack of logical flow.
ChatGPT+def	Relevance: 2 Consistency: 1 Fluency: 2 Coherence: 1 Explanation: The summary is not relevant as it does not capture the key points of the article. It is inconsistent with the facts in the original article, as it incorrectly states that Andros Townsend scored in the 89th minute, when in fact he was brought on in the 83rd minute. The fluency of the summary is poor, with grammatical errors and incomplete sentences. The coherence of the summary is also poor, as it does not flow well and does not make sense as a whole.

Table 7: Examples of ratings and explanations generated by ChatGPT. The **red** parts show the factual errors of the summary. The **blue** parts show the explanations for fluency and coherence. The long source document is not shown. "Expert Annotator" shows the average of scores given by three expert annotators, with each person's score in parentheses.

RAGAS

- RAGAS è un framework progettato per valutare le risposte generate in un sistema di tipo RAG usando l'approccio LLM as a judge



RAGAS – Context Recall

- Misura quanti documenti o informazioni rilevanti (Ground Truth - GT) sono stati recuperati con successo.
- Si concentra sul non perdere risultati importanti.
- Maggiori valori di recall indicano che pochi documenti rilevanti sono stati esclusi.

$$\text{Context recall} = \frac{|\text{GT claims attributed to the context}|}{|\text{GT claims}|}$$

RAGAS – Context Precision

- Misura la proporzione di chunk rilevanti nel contesto recuperato.
- Viene calcolata come la media della *precision@k* per ogni chunk nel contesto.
- *precision@k*: rapporto fra il numero di chunk rilevanti a rango k e il numero totale di chunk a rango k , ovvero i top k risultati.

RAGAS – Context Precision

$$\text{Context Precision@K} = \frac{\sum_{k=1}^K (\text{Precision@k} \times v_k)}{\text{Total number of relevant items in the top } K \text{ results}}$$
$$\text{Precision@k} = \frac{\text{true positives@k}}{(\text{true positives@k} + \text{false positives@k})}$$

v_k indica la rilevanza al rango k

RAGAS – Faithfulness

- Misura l'accuratezza fattuale delle risposte generate verificando se le affermazioni fatte nelle risposte sono supportate dal contesto fornito.
- Viene calcolata analizzando la validità di ogni affermazione derivata dalla risposta generata rispetto al contesto.

$$\text{Faithfulness} = \frac{\# \text{ valid statements}}{\# \text{ statements}}$$

RAGAS – Answer Relevancy

- *Answer relevancy*: media della cosine similarity fra la domanda originale e un set di domande generate a partire dalla risposta prodotta.
- Misura quanto la risposta generata sia rilevante e direttamente correlata alla domanda posta.
- Valuta la somiglianza tra domande probabili che potrebbero suscitare la stessa risposta e la domanda effettiva posta.

RAGAS – Answer Relevancy

$$\text{answer relevancy} = \frac{1}{N} \sum_{i=1}^N \cos(E_{g_i}, E_o)$$

$$\text{answer relevancy} = \frac{1}{N} \sum_{i=1}^N \frac{E_{g_i} \cdot E_o}{\|E_{g_i}\| \|E_o\|}$$

tipicamente $N = 3$

Librerie

- Constraint decoding
 - <https://dottxt-ai.github.io/outlines/latest/>
- Evaluate
 - <https://huggingface.co/docs/evaluate/index>
- RAGAS
 - <https://docs.ragas.io/en/stable/>