



Università
degli Studi
di Palermo




Retrieval-Augmented Generation

CORSO DI NATURAL LANGUAGE PROCESSING (ELABORAZIONE DEL LINGUAGGIO NATURALE)

a.a. 2025/2026

Prof. Roberto Pirrone



Overview

 Introduzione

 RAG

 Componenti

 Vantaggi

 Metriche

 Librerie

 Caso di studio: Unipa-GPT



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Introduzione

Quando chiediamo ad un LLM di generare una risposta, per esempio in un contesto di QA, possiamo usare un Base o Instruct LLM o effettuare il finetuning su un LLM per il QA.

Base/Instruct LLM	FT LLM
✓ inferenza	✗ finetuning + inferenza
✓ costi di inferenza	✗ finetuning e costi di inferenza
✗ allucinazioni	✓ risposte di alta qualità
✗ outdated information	✓ informazioni aggiornate grazie al data set per il FT



Retrieval-Augmented Generation (RAG)

Consideriamo uno studente che deve affrontare un esame



Studente che non
ha studiato

Base LLM



Studente che ha
studiato

FT LLM



Studente che ha
accesso al libro

Base LLM con **RAG**



Università
degli Studi
di Palermo

dj dipartimento
di ingegneria
unipa



Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) è

- Una tecnica avanzata che combina la fase di recupero delle informazioni (retrieve) e generazione del testo (generation) per migliorare le capacità di un LLM senza la necessità di una fase di fine-tuning.

Retrieval-Augmented Generation (RAG)


Retrieval-Augmented Generation (RAG) è

- Utilizza il concetto di memoria non-parametrica per il retriever e memoria parametrica per il generator.
- Il retriever è statico, non ci sono parametri, mentre il modello, ovvero il generator, ha una memoria dipendente dai suoi pesi.


Retrieval-Augmented Generation (RAG)

- Le informazioni rilevanti sono recuperate a partire da una base di conoscenza (Knowledge Base) o da sorgenti esterne.
- Il contenuto recuperato è utilizzato per condizionare la risposta del modello che diviene grado di generare risposte di alta qualità e coerenti rispetto al contesto recuperato.


Retrieval-Augmented Generation (RAG)



Retrieval-Augmented Generation (RAG)






Retrieval-Augmented Generation (RAG)



Corpus

- Dati sui quali il modello si basa per generare le sue risposte e che popolano il retriever
 - Dati del dominio di interesse organizzati in documenti testuali
 - Dati in formati strutturati quali JSON, grafi
 - Dati privati




Università
degli Studi
di Palermo

d*i* dipartimento
di ingegneria
unipa




Embeddings LLMs

- I dati collezionati sono divisi in piccole sezioni, chiamate *chunk*
- I chunk sono opportunamente codificati da un “Embedding LLM”, ovvero un LLM finalizzato alla generazione delle loro rappresentazioni vettoriali dense (embedding)



Embedding LLM

Delvin et al, 2017
Attention is all you need



Retriever

- L'obiettivo è ottenere i documenti più rilevanti per una data query e di conseguenza migliorare la generazione della risposta
- I chunk ottenuti sono memorizzati in un vector store, un database vettoriale indicizzato che consente un'efficiente memorizzazione e accesso ai vettori ivi memorizzati.
 - Chroma, Faiss, Pinecone, Neo4j

Retriever

- Una *similarity function* determina e ordina, data una query, i top k chunks D_i all'interno della collezione C del vector store
 - Cosine similarity
 - MMR (Maximum Marginal Relevance)

$$MMR \stackrel{\text{def}}{=} \operatorname{argmax}_{D_i \in R \setminus S} \left[\lambda * \operatorname{Sim}_1(D_i, Q) - (1 - \lambda) * \max_{D_j \in S} (\operatorname{Sim}_2(D_i, D_j)) \right]$$

- Q : query
- R lista ordinata dei chunk estratti dal retriever
- S insieme dei documenti già forniti all'utente
- $\lambda = 0 \rightarrow$ massima diversità; $\lambda = 1 \rightarrow$ massima rilevanza rispetto alla query

Generator

- LLM generativi decored-only che generano una risposta dato un prompt composto da un'istruzione, il contesto recuperato e la query utente.

Usa il seguente CONTESTO per rispondere alla DOMANDA.
Se non conosci la risposta, rispondi dicendo che non lo sai, non provare a fornire una risposta.
Usa al massimo tre frasi e mantieni la risposta quanto più concisa possibile.
Concludi ogni risposta dicendo "grazie per aver chiesto!".

CONTESTO: {contesto}

DOMANDA: {domanda}

RISPOSTA:

RAG – vantaggi

Risposte di alta qualità

Framework adattabile a vari domini senza l'uso di fine-tuning

LLMs possono accedere a specifiche informazioni aggiornate

Maggiore controllo sui dati generati (source documents)

È possibile utilizzare risorse on-budget

RAG – valutazione


- **Retriever**

- Precision, accuracy
- Context relevancy (LLM as a judge)
- Valutazione umana

- **Generation**

- BLEU, ROUGE, BERT-score, Perplexity
- Faithfulness, correctness (LLM as a judge)
- Valutazione umana

RAG – miglioramenti



RAG e grafi

- Le tecniche basate su RAG possono essere estese a basi di dati più complesse, dove i dati sono organizzati in strutture a grafo e memorizzate di conseguenza.
- Un *knowledge graph* organizza le informazioni in triplette:
 $\langle \text{subject}, \text{relation}, \text{object} \rangle$
e possono essere costruite manualmente o generate tramite LLM.

RAG e grafi

- Le tecniche basate su RAG possono essere estese a basi di dati più complesse, dove i dati sono organizzati in strutture a grafo e memorizzate di conseguenza.
- Un *graph database* memorizza le informazioni seguendo un paradigma a grafo e può essere interrogato attraverso opportuni linguaggi di query, come Cypher.

RAG e grafi

MPX2601 is a clinical report of a 68 y.o. female patient suffering from a Lipomatous hypertrophy of the interatrial septum displayed in CT w/contrast (IV). Shortness of breath with concern for pulmonary embolism. The disease Lipomatous hypertrophy of the interatrial septum located in Cardiovascular (Thorax) and it can be treated in this way: can be treated in this way: No specific treatment necessary.. About Lipomatous hypertrophy of the interatrial septum we can say that: Lipomatous hypertrophy of the interatrial septum (LHAS) is a benign process characterized by accumulation of fat within the interatrial septum. The incidence of LHAS is 1% in autopsy series and increases with increasing age and obesity. This lesion is of little clinical significance; patients with LHAS have slightly higher risk of supraventricular tachycardia, and several cases of hemodynamically significant SVC obstruction have been reported. Otherwise, LHAS tends to be an incidental finding.

At imaging, LHAS demonstrates fat attenuation and follows the signal intensity of fat on MR sequences. Narrowing of the lesion around the fossa ovalis lends the lesion a dumbbell-shaped contour.

The presence of fat in a cardiac mass excludes lesions such as myxomas, fibromas, and fibroelastosis. Cardiac lipomas are uncommon lesions and tend to be subendocardial or subpericardial in location, and generally a capsule can be found at imaging. Cardiac liposarcomas are extremely rare, often presenting with metastases or cardiac constrictive symptoms. .



Università
degli Studi
di Palermo

dipartimento
di ingegneria
unipa



RAG e grafi

MPX2601 is a clinical report of a 68 y.o. female patient suffering from a Lipomatous hypertrophy of the interatrial septum displayed in CT w/contrast (IV). Shortness of breath with concern for pulmonary embolism. The disease Lipomatous hypertrophy of the interatrial septum located in Cardiovascular (Thorax) and it can be treated in this way: can be treated in this way: No specific treatment necessary.. About Lipomatous hypertrophy of the interatrial septum we can say that: Lipomatous hypertrophy of the interatrial septum (LHAS) is a benign process characterized by accumulation of fat within the interatrial septum. **The incidence of LHAS is 1% in autopsy series** and increases with increasing age and obesity. This lesion is of little clinical significance; patients with LHAS have slightly higher risk of supraventricular tachycardia, and several cases of hemodynamically significant SVC obstruction have been reported. Otherwise, LHAS tends to be an incidental finding.

At imaging, LHAS demonstrates fat attenuation and follows the signal intensity of fat on MR sequences. Narrowing of the lesion around the fossa ovalis lends the lesion a dumbbell-shaped contour.

The presence of fat in a cardiac mass excludes lesions such as myxomas, fibromas, and fibroelastosis. Cardiac lipomas are uncommon lesions and tend to be subendocardial or subpericardial in location, and generally a capsule can be found at imaging. Cardiac liposarcomas are extremely rare, often presenting with metastases or cardiac constrictive symptoms. .

*Inferenza del grafo con
Llama 3.1 8B instruct*



RAG e grafi

MPX2601 is a clinical report of a 68 y.o. female patient suffering from a Lipomatous hypertrophy of the interatrial septum displayed in CT w/contrast (IV) . Shortness of breath with concern for pulmonary embolism. The disease Lipomatous hypertrophy of the interatrial septum located in Cardiovascular (Thorax) and it can be treated in this way: can be treated in this way: No specific treatment necessary.. About Lipomatous hypertrophy of the interatrial septum we can say that: Lipomatous hypertrophy of the interatrial septum (LHAS) is a benign process characterized by accumulation of fat within the interatrial septum. **The incidence of LHAS is 1% in autopsy series and increases with increasing age** and obesity. This lesion is of little clinical significance; patients with LHAS have slightly higher risk of supraventricular tachycardia, and several cases of hemodynamically significant SVC obstruction have been reported. Otherwise, LHAS tends to be an incidental finding.


At imaging, LHAS demonstrates fat attenuation and follows the signal intensity of fat on MR sequences. Narrowing of the lesion around the fossa ovalis lends the lesion a dumbbell-shaped contour.

The presence of fat in a cardiac mass excludes lesions such as myxomas, fibromas, and fibroelastosis. Cardiac lipomas are uncommon lesions and tend to be subendocardial or subpericardial in location, and generally a capsule can be found at imaging. Cardiac liposarcomas are extremely rare, often presenting with metastases or cardiac constrictive symptoms.

Inferenza del grafo con Llama 3.1 8B instruct



RAG e grafi




RAG e grafi

- Le relazioni tra le entità sono maggiormente evidenziate.
- Gli algoritmi di esplorazione del grafo sono migliori per il retrieval.
- Invece di recuperare elementi di interesse grezzi, si ottengono relazioni e dati maggiormente strutturati, e vengono usati come contesto per la generazione del test, ottenendo quindi un modello *capace di collegare i puntini*.


RAG e ontologie

- Un'ontologia è un metodo formale per modellare uno specifico dominio di conoscenza tramite classi, attributi e relazioni.
- Opera esplicitamente *a livello semantico* e riesce a catturare relazioni complesse tra classi attraverso un apposito linguaggio di query: SparQL




Agentic RAG

- Paradigma di integrazione del RAG all'interno di un'architettura ad agenti in cui uno o più agenti LLM cooperano per il task di retrieval




Agentic RAG

- Paradigma di integrazione del RAG all'interno di un'architettura ad agenti in cui uno o più agenti LLM cooperano per il task di retrieval




Agentic RAG

- Paradigma di integrazione del RAG all'interno di un'architettura ad agenti in cui uno o più agenti LLM cooperano per il task di retrieval




Agentic RAG


- Paradigma di integrazione del RAG all'interno di un'architettura ad agenti in cui uno o più agenti LLM cooperano per il task di retrieval



Single Agent RAG



Multi-agent RAG



Librerie

-  LangChain
 - <https://python.langchain.com/docs/introduction/>
-  LlamaIndex
 - <https://docs.llamaindex.ai/en/stable/>



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa

